


사람들의 관심 급증은 지속 상승하는가, 과열된 고점인가?

BDAI FinDA D조 · 조현정 · 김지은 · 전소정



출발점: FOMO와 고점 공포

“지금 안 사면 더 오르지 않을까?”


“사람들이 다 알면 이미 고점 아닐까?”



✓ 관심이 몰리며 급등한 종목은 이후에도 상승하는가,
아니면 상승분을 반납하고 결국 하락하는가?

출발점: FOMO와 고점 공포

Solution:




급등한 종목에 대해 초보투자자가 “진입해도 되는지?”에 대해
추격 진입 위험을 설명하는 의사결정 보조 대시보드

01

데이터 수집

서로 다른 원천을 급등 사건 단위 분석 데이터로 연결



[주가데이터]: 종목·일자 기준 분석 데이터 구성

분석 기준

KOSPI200 구성종목 이력

정기변경·수시편입/편출 반영
종목 × 거래일 기준으로 정렬

수집기간

2021.06.11 — 2026.06.11

01 주가·거래량
시가·고가·저가·종가, 거래량, 거래대금

02 시장지수
KOSPI·KOSDAQ·KOSPI200 지수 증가, 일간수익률

03 투자자별 수급
개인·외국인·기관 매수·매도·순매수 거래대금

04 기업가치·외국인 보유
시가총액, PER/PBR/EPS, 외국인 보유수량·지분율

05 공매도
공매도 거래·잔고, 공매도 금지기간 플래그



동일 기간·종목 기준으로 결합해 이벤트 분석용 일별 패널 구성

KOSPI200 구성종목 이력을 기준으로 5개 데이터군을 같은 기간·종목 기준으로 정렬

[관심지표-뉴스]: BigKinds에서 종목별 검색식으로 수집

GS	2021-06-11	28	GS NOT GS건설 NOT GS리테일
GS	2021-06-12	4	GS NOT GS건설 NOT GS리테일
GS	2021-06-13	19	GS NOT GS건설 NOT GS리테일
GS	2021-06-14	32	GS NOT GS건설 NOT GS리테일
GS	2021-06-15	33	GS NOT GS건설 NOT GS리테일

실제 검색어 그룹 예시

두산 NOT 두산로보틱스 NOT 두산밥캣
(대상 AND 청정원) OR (대상 AND 종가집)

※ 관련검색어는 검색 결과에서 실제 종목을 지칭하는지 확인한 뒤 채택

[BigKinds 수집 결과]

종목별·날짜별 뉴스 기사 수

종목코드 · 종목명 · 날짜 · 뉴스기사수 · 검색식

BigKinds 검색식 설계

현재 종목명·과거 종목명·약칭을 결합
동음이의어·일반명사 혼입어는 제외

날짜별 기사 수와 실제 검색식 함께 보존

뉴스 기사 수와 실제 사용 검색식을 함께 저장해 필터링·검증·재수집이 가능하도록 설계

[관심지표-검색량]: 네이버 데이터랩에서 종목별 검색어 그룹을 직접 설계해 수집

HD현대중공업	2026-06-12	56.37485	TRUE	HD현대중공업 HD현대중공업 주가 현대중공업 현대중공업 주가
하이브	2026-06-12	60.9561	TRUE	하이브 하이브 주가
SK아이이테크놀로지	2026-06-12	67.97966	TRUE	SK아이이테크놀로지 SK아이이테크놀로지 주가 SKIET SKIET 주가
LG에너지솔루션	2026-06-12	27.41298	TRUE	LG에너지솔루션 LG에너지솔루션 주가 LG엔솔 LG엔솔 주가

실제 검색어 그룹 예시

HD현대중공업 | HD현대중공업 주가 | 현대중공업 | 현대중공업 주가
SK아이이테크놀로지 | SKIET | SKIET 주가

※ 관련검색어는 검색 결과에서 실제 종목을 지칭하는지 확인한 뒤 채택

[관련검색어 추가 기준]

실제 종목 연관성 확인

통합검색·뉴스 용례를 확인하고
동음이의·계열사 혼입어는 제외

약칭·과거 종목명 처리


현재 종목명 + '주가'를 기본어로 사용
공식 명칭·시장 통용 약칭을 함께 포함
사명 변경 종목은 과거·현재 명칭을 OR 결합

검색어 그룹과 일별 상대검색량(0~100)을 함께 저장해 동일 기준으로 재수집할 수 있게 했다.

01-B

데이터 전처리

서로 다른 원천을 급등 사건 단위 분석 데이터로 연결



주가·거래량·수급

pykrx / KRX

검색 관심

Naver DataLab

뉴스 관심

BigKinds

공매도·시장

pykrx / 지수

260개

Historical KOSPI200 종목

약 1,250건

미래성과 관측 가능 급등사건

2021–26

Walk-forward·미래구간 검증

달력일 관심 데이터와 거래일 시장 데이터를 급등사건일 기준으로 정합화하고, Train fold 내부에서 결측·분위수를 처리했다.

01

종목 Universe

KRX 구성 이력

KOSPI200 편입·편출 이력 수집
거래일별 실제 구성종목 확정

02

가격·수급·기업가치

pykrx API

일별 OHLCV·거래대금·외국인/기관
PER·PBR·시가총액 일괄 조회

03

검색·뉴스 관심DataLab API ·
BigKinds

DataLab: 일별 상대검색량(0~100)
BigKinds: 검색식별 일간 뉴스 기사 수

04

공매도·시장

pykrx · KRX

공매도 거래량·거래대금·잔고 수집
시장지수와 금지기간 flag 결합

원천 CSV/Parquet → GCS 저장 → DuckDB에서 ticker·date 기준 병합

01

유니버스 정합화

261 → 260종목

잘못 매핑된 001260 제외
원본은 raw에 보존

02

시간축 분리

거래일 ≠ 달력일

주가·공매도는 거래일
검색·뉴스는 달력일 유지

03

결측·오류 복구

공매도 9개 열
100% 결측

단수/복수 컬럼명 표준화
공개시차 T+2 적용

04

누수 방지


Train Fold 내부 처리

Attention 초기 50일 및 거래일이 아닌 날짜의
구조적 결측 시장변수도 fold별 재계산

최종 결과: 260종목 · 253,111행 · ticker+date 중복 0건

GCS = Google Cloud Storage


파일을 저장하는 클라우드 공간이며,
이 프로젝트에서는 검증된 Parquet의 Source of Truth로 사용했다.



gs://finda_project/curated/ | CSV 반복 병합 대신 동일한 Parquet 정제본을 팀 공용으로 재사용

DuckDB = 파일을 직접 읽는 내장형 분석 SQL 엔진

클라우드 저장소가 아니라
Join·Filter·Feature 계산을 반복 가능하게 만든 분석 계층




효과: 실험마다 Python에서 전체 Join·Filter·Feature를 다시 계산하지 않고 SQL View와 Event Snapshot을 재사용

02-A


가설검증 - 관심지표

급등 기준을 정하고 관심지표·수급 가설의 타당성을 확인




1. 급등 기준 설정: 무엇을 “급등”이라고 볼 것인가


단순 하루 이상치가 아니라 가격 상승과 거래 참여가 함께 확대된 상태



+20% 이상 상승
누적된 가격 상승



직전 20일 평균 대비
거래량 증가



cooldown
동일 상승국면 중복 방지

가격 상승

+

거래 참여

=

급등 사건


→ 최종적으로는 일정 기간 가격이 충분히 상승했고,
동시에 거래량까지 증가한 상태를 급등 사건으로 정의했습니다.

가격만 오른 게 아니라 실제 시장 참여까지 확대된
‘관심을 받을 만한 급등 상태’를 포착하기에 가장 적당한 기준

초기 탐색에서 여러 정의를 검토했지만, 본 분석에서는 해석 가능성이 높은
기준을 고정해 사용했습니다.

02. 1차 분류 기준 설정: 지속 상승형 | 관망형 | 과열 반전형


전체 사건 평균에서는 급등 직전부터 관심이 상승했고, 유형별로 검색과 뉴스의 유지 패턴이 다르게 나타났다.



→ 검색은 투자자의 관심 흐름을, 뉴스는 언론의 사건 반응 강도를 더 잘 반영했을 가능성이 있다.

03. 관심도 분위별 급등이후 시장조정 누적수익률

사전 검색 관심도가 높은 종목일수록 급등 이후 시장조정 누적수익률이 낮게 나타났다



급등 기준 + 관심지표

+8.9%

PR-AUC 개선 | 0.04462 → 0.0503


가설 검증 결과

관심 상위 그룹의 상대성과가 더 낮았고
급등 기준에 대한
PR-AUC는 8.9% 개선됐다.

관심도가 상대적으로 높은 그룹의 시장조정 누적수익률이 상대적으로 낮다.

03. 관심도 분위별 급등이후 시장조정 누적수익률

사전 검색 관심도가 높은 종목일수록 급등 이후 시장조정 누적수익률이 낮게 나타났다



이 결과가 정말 “관심” 때문일까?

급등 기준 + 관심지표

+16.8%

PR-AUC 개선 | 0.04475 → 0.05226

가설 검증 결과

관심 상위 그룹의 상대성결과가 더 낮았고
급등 기준에 대한
PR-AUC는 16.8% 개선됐다.

관심도가 상대적으로 높은 그룹의 시장조정 누적수익률이 상대적으로 낮다.

03. 관심도 분위별 급등이후 시장조정 누적수익률

사전 검색 관심도가 높은 종목일수록 급등 이후 시장조정 누적수익률이 낮게 나타났다

이 결과가 정말 “관심” 때문일까?

의문 1


대형주·중형주·소형주가 섞여
착시가 생긴 것은 아닐까?

의문 2

주가가 이미 올랐기 때문에
사람들이 검색한 것은 아닐까?

A. 상대적 기업규모별 이후 방향성

기업규모를 나눠 봐도 급등 이후 방향성은 비슷하게 낮았다



의문 1


**대형주·중형주·소형주가 섞여
착시가 생긴 것은 아닐까?**

의문 2

**주가가 이미 올랐기 때문에
사람들이 검색한 것은 아닐까?**

B. 검색관심도 분위별 기업규모 구성비

관심도 분위별 기업규모 구성비는 크게 다르지 않아 규모 혼입 가능성은 낮았다



의문 1

**대형주·중형주·소형주가 섞여
착시가 생긴 것은 아닐까?**


의문 2

**주가가 이미 올랐기 때문에
사람들이 검색한 것은 아닐까?**

분석 1) 관심지표 **선행성** x 상승지속성 분석

FINDA · 초기 가설검증

중요한 것은 관심의 “타이밍”일까?



의문 2

주가가 이미 올랐기 때문에
사람들이 검색한 것은 아닐까?

선행일수 정의

$\text{lead_days} = \text{급등일} - \text{관심 급증 진입일}$

검색 중앙값 0일


뉴스 중앙값 2일

→ 검색은 0~2일에 1,033건 집중, 뉴스는 3~20일 선행도 477건으로 더 넓게 분포했다.

분석 1) 관심지표 **선행성** x 상승지속성 분석

FINDA · 초기 가설검증

검색 선행일수는 이후 수익률을 안정적으로 설명하지 못했다



결과 1

검색이 먼저 나타나도
미래 경로는
뚜렷하게 달라지지 않았다

Spearman: search lead → final return


- H10 $\rho = -0.016$, $p = .576$
- H20 $\rho = +0.002$, $p = .955$
- H40 $\rho = -0.005$, $p = .866$

→ 검색은 급등과 거의 동시에 따라붙는 대중 반응에 가까웠고, 선행일수 자체는 상승지속성을 설명하지 못했다.

분석 1) 관심지표 **선행성** x 상승지속성 분석

FINDA · 초기 가설검증

반면 뉴스 선행에서는 약한 상승지속성 관계가 관찰됐다



결과 2

뉴스가 더 먼저 나타난 사건은
H40 중앙 수익률이 더 높았다

해석 기준

- No signal: -0.5%
- 0~2일: +2.2%
- 3~20일: +4.5~5.3%


단, 그룹 검정은 $p=.0513$ 으로 경계적이므로
강한 예측 신호가 아니라 탐색적 패턴으로 해석

→ 관심 선행 가설은 전체적으로 지지된 것이 아니라, 뉴스에서만 부분적으로 관찰된 약한 관계로 정리했다.

분석 1) 관심지표 **선행성** x 상승지속성 분석

FINDA · 초기 가설검증

사건 당시 조건을 통제해도 뉴스 선행 관계는 약하게 남았다



결과 3

통제 후에도 H20에서만
약하게 유지됐다

Adjusted OLS: news lead → final BHAR

- H20 +0.273%p, $p=.037$
- H40 +0.348%p, $p=.053$
- H10 비유의, $p=.395$


급등폭·거래량·변동성·시총·수급·시장환경·연도 통제

→ 뉴스 선행은 강한 예측 신호가 아니라, 일부 정보성이 남는 탐색적 패턴으로 정리했다.

분석 2) 관심지속성 x 주가분석

FINDA · 초기 가설검증

관심 지속성에 따른 주가는 어떨까? 관심이 오래 지속되면 수익률이 더 좋을까?



결과 1

검색 관심이 오래 유지될수록
H20/H40 성과는 오히려 낮아졌다

OLS: search high_share_7 → final return

- H20 -0.71%p, p=.004
- H40 -1.16%p, p=.002
- 기대 방향과 반대


관심 지속이 곧 상승 지속이라는 가정은 유지
되지 않았다

→ 검색 관심 지속성은 상승 지속 신호가 아니라, 과열 관심이 오래 남아있는 상태일 가능성이 있었다.

분석 2) 관심지속성 x 주가분석

FINDA · 초기 가설검증

뉴스 지속성 역시 상승 지속보다 낙폭 확대와 더 가까웠다



결과 2

뉴스 고지속 그룹은
H20 최대낙폭이 더 컸다

News persistence group별 H20 MDD

- Low -12.90%
- Mid -13.58%
- High -19.75%

뉴스가 많아서 오른 것이 아니라, 변동성·사건
반응이 큰 종목일 수 있음

→ 관심이 오래 유지되면 더 좋다는 지속성 가설도 일관되게 지지되지 않았다.

가설 검증 결과

관심지표의 역할을 다시 정의했다.

처음 기대

관심 급증 → 이후 과열 · 지속 판단 신호

실제로 확인

관심 수준 · 선행성 · 지속성만으로는
이후 방향을 안정적으로 설명하기 어려웠다

결론

예측변수라기보다 시장이 얼마나
주목했는지를 설명하는
“**상황정보**”에 가깝다.


다음 질문

그렇다면, 급등 당일 우리가 알 수 있는 정보 중
이후 주가 방향성을 **가장 잘 구분하는** 변수는 무엇일까?

02-B


가설검증 - 주가데이터

급등 당일 우리가 알 수 있는 정보 중 이후 주가 방향성을 가장 잘 구분하는 변수는 무엇일까?



급등 당일, 이후 주가 방향성을 가장 잘 구분하는 변수는 무엇일까?

관심지표만으로는 부족했다면, T 이전 20거래일의 61개 변수 중 무엇이 T+20 부진위험을 가장 잘 구분하는지 비교했다



Best single-variable

[가격 + 변동성]

AUC $\approx$ 0.616

가장 강한 변수도 단독으로는
T+20 부진위험을
충분히 구분하지 못했다.

추가적으로,
외국인 보유비중이 높은 사건이
상대적으로 비부진 쪽에 가까웠다




결론: 급등 이전의 가격·변동성 정보가 가장 큰 힌트를 주었지만, 단일 변수의 구분력은 제한적이었다

변수군으로 묶어보면 무엇이 더 안정적인가?


가격·변동성은 꾸준했고, 수급의 구분력은 시장 국면에 따라 달라졌다

Maximum Separation by Feature Family



변수군 단위로 봐도
가격·변동성 맥락(Stock Context)이 가장 컸다

Yearly Separation Strength by Feature Family



수급 주체는 연도별로 크게 흔들렸지만,
Stock Context는 비교적 안정적이었다



결론: 가격·변동성은 비교적 안정적이었지만, 수급은 연도별로 흔들렸다

단변량 검정의 한계, 그래서 변수 조합을 봤다

가격·변동성은 꾸준했고, 수급의 구분력은 시장 국면에 따라 달라졌다

1 단변량 검정



개별 변수는
일부 힌트만 제공

2 한계



사건 당일까지의 **단변량 검정**에서는 관
심지표의 유의성을 보기 힘들다

3 다음 단계



조건부 관계·비선형 조합을 보기 위해
feature ablation 분석




결론: 가격·변동성·수급은 일부 힌트를 줬지만, 단일 변수만으로는 부족했다.
그래서 **변수들의 조합을 비교**하는 feature ablation 기반 모델 분석으로 넘어갔다.

03-A

분석방향 설정

3분류의 한계에서 Peak Give-back과 Direct T+20으로



지속상승형

상승분을 유지

관망형

방향이 불명확

단기과열형

상승 후 큰 반납

라벨 정의 10종

×


알고리즘 3종

=

30개 Walk-forward 조합

순위	라벨	모델	macro AUC	macro F1
1	label_zcar	XGBoost	0.607	0.319
2	label_bhar_mdd	Logistic	0.563	0.344
3	label_zcar	RF	0.559	0.310
4	label_bhar_mdd_relaxed	Logistic	0.556	0.315
5	label_cluster	RF	0.548	0.330
6	label_cluster	XGBoost	0.540	0.298
7	label_cluster	Logistic	0.539	0.309
8	label_bhar_mdd	RF	0.538	0.346
9	label_slope	RF	0.536	0.349
	... (중략, 총 30개 중 21개 생략)			
28	label_ratio_v2	XGBoost	0.505	0.251
29	label_bhar_only	RF	0.502	0.330
30	label_bhar_only	XGBoost	0.486	0.311
—	label_zcar	Logistic	0.451	0.249

30개 조합의 Macro AUC




같은 라벨(label_zcar)에서
알고리즘만 바꿨을 때의 점수

라벨·알고리즘 조합에 따라 결과가 크게 흔들림

문제: 라벨 방식에 따라 클래스 분포가 급변했고, 같은 라벨도 알고리즘에 따라 결과가 뒤집혔다.

대표 BHAR/MDD 라벨 Recall

단기과열형  43-65%

지속상승형  4.8-7.7%

SMOTE 후 지속상승 Precision 0.12

불균형 처리로도 클래스 혼동은 해소되지 않음

알고리즘	실제 클래스	표본수	예측_관망형	예측_단기과열형	예측_지속상승형	Recall
Logistic	관망형	268	110	82	76	41.0%
	단기과열형	651	190	281	180	43.2%
	지속상승형	104	33	37	34	32.7%
RandomForest	관망형	268	135	125	8	50.4%
	단기과열형	651	215	413	23	63.4%
	지속상승형	104	40	59	5	4.8%
XGBoost	관망형	268	95	155	18	35.4%
	단기과열형	651	195	423	33	65.0%
	지속상승형	104	37	59	8	7.7%

3개 알고리즘 모두에서 동일한 패턴이 재현된다 :

- 단기과열형은 상대적으로 잘 구분된다 (recall 43~65%)
- 지속상승형은 RF·XGBoost에서 사실상 탐지되지 않는다 (recall 4.8%~7.7% — 104건 중 5~8건만 맞힘)
- 관망형↔단기과열형 사이의 혼동이 압도적으로 많다 (RF 기준 관망형의 46.6%가 단기과열형으로 오분류)

**3분류의 구조적 한계를 확인하고,
신호가 존재한 ‘단기과열형 vs 나머지’로 분석 질문을 전환했다.**

**여기서 확인한 이진분류의 구분 가능성이,
점차 회피·매수 신호를 만드는 방향으로 흘러가고 있었다.**

분류 질문의 전환

기존 3분류 모델

관망형 · 단기과열형 · 지속상승형을 한 번에 분류

문제: 경로 전체를 맞추기

관망↔지속상승 혼동이 반복되고 성능이 불안정

하락위험 점수모델

상위 20% → 회피 후보

상승지속 점수모델

상위 20% → 매수 후보

상위 구간에서 확인된 실제 경로 차이

연도	매수 정밀도	위험 혼입률	매수 BHAR 증양값	회피 정밀도	회피 BHAR 증양값
2025	70.21%	8.51%	+12.81%	77.78%	-7.95%
2026	50.00%	25.00%	+17.48%	60.00%	+32.78%

핵심은 모든 경로의 이름을 맞추는 것이 아니라,
각 점수의 극단 구간을 순위로 선별하는 것이었다.

매수 후보는 두 연도 모두 BHAR 증양값이 양수였지만,
회피 후보는 2026년에 방향이 뒤집혀 안정성이 낮았다.

이진 점수모델은 매수 후보의 상대적 경로 차이는 포착했지만, 회피 규칙까지 안정적으로 확정하지는 못했다.

분류 질문의 전환

기존 3분류 모델

관망형 · 단기과열형 · 지속상승형을 한 번에 분류

하락위험 점수모델

상위 20% → 회피 후보

문제: 경로 전체를 맞추기

관망↔지속상승 혼동이 반복되고 성능이 불안정

상위 구간에서 확인된 실제 경로 차이

연도	매수 정밀도	위험 혼입률	매수 BHAR 증양값	회피 정밀도	회피 BHAR 증양값
2025	95.2%	1.5%	12.1%	77.78%	-7.95%
2026	90.1%	2.5%	17.4%	72.22%	+32.78%

따라서 이 결과는 ‘절대적 매매 규칙’이 아니라,
3분류 실패 이후 분석 질문을 좁힐 수 있었던 탐색 근거로 사용했다

* 앞에서 사용했던 3분류 모델과는 다른 모델이다

핵심은 모든 경로의 이름을 맞추는 것이 아니라,
각 점수의 극단 구간을 순위로 선별하는 것이었다.

매수 후보는 두 연도 모두 BHAR 증양값이 양수였지만,
회피 후보는 2026년에 방향이 뒤집혀 안정성이 낮았다.


이진 점수모델은 매수 후보의 상대적 경로 차이는 포착했지만, 회피 규칙까지 안정적으로 확정하지는 못했다.

05

EWMA 상승/하락 장벽 ABCD 매수·회피 모델

최종 수익률 자체가 아니라, 급등 이후 의미 있는 상승·하락 움직임 중 어느 쪽이 먼저 나타나는지 본다

First-touch Barrier Target



Buy first

Risk first

Neither

장벽은 “수익 보장선”이 아니라 Target 정의

종목별 변동성을 반영한 $\pm k \times \text{EWMA}$ 장벽을 만들고,
20거래일 안에 어느 장벽을 먼저 터치했는지로
buy/risk target 생성

상승 장벽
먼저 터치
buy_target=1

하락 장벽
먼저 터치
risk_target=1

둘 다 X
Neither


강건성 검증: 2021~2024 OOF에서 hl 5/10/20 $\times$ k 1.0/1.5/2.0 후보를 비교하고,
발표용 기준으로 hl10 $\times$ 1.5를 사용

핵심
해석

“장벽을 터치하면 대부분 오른다”가 아니라,
급등 이후 단기적으로 상승·하락 중 어느 반응이 먼저 나오는지를 분류하기 위한 기준이다.

Feature Ablation A/B/C/D 설계: 관심지표의 추가효과 분리 분석

같은 Event · 같은 Target · 같은 LightGBM · 같은 Walk-forward 조건에서 Feature set만 바꿔 비교했다



검증
방식

Purged Expanding Walk-Forward + OOF Top20 threshold

Buy/Risk 분리
LightGBM

BHAR·MDD는 사후 성과평가

단, 절대 예측 성능은 강하지 않아 “강한 투자모델”이 아니라 추가 정보 실험으로 해석했다

Baseline hl10 × 1.5σ · 20D

관심효과 깔끔

지표	A→B	D→C
Buy 실제 Buy	+9.32%p	+6.26%p
Buy 실제 Risk	-8.62%p	-7.27%p
Avoid 실제 Risk	+4.69%p	+8.39%p
Avoid 실제 Buy	-3.13%p	-7.77%p

A→B와 D→C 모두 4/4 방향에서 기대방향 개선

Sensitivity hl20 × 1.0σ · OOF A→B

민감도 예시

Buy actual Buy	+6.10%p	
Buy actual Risk	-7.32%p	
Avoid actual Risk	+1.83%p	
Avoid actual Buy	-1.83%p	
Buy-Avoid BHAR gap	+3.28%p	

주의: 장벽 설정에 따라 효과 크기가 달라짐.
“강한 예측”이 아니라 “관심지표의 보조 정보”로 제한 해석

결론: 관심지표는 장기 수익률을 직접 설명하는 핵심 변수라기보다, 급등 이후 단기 상승/하락 장벽 순서 분류에서 추가 정보를 제공했다.

08

핵심 한계: First-touch는 최종 수익률을 보장하지 않는다

상승 장벽을 먼저 터치해도 이후 반납이 크면 T+20에는 부진할 수 있다



핵심 한계

T+3에 상단 장벽을 먼저 돌파해도
이후 급락해 T+20에 부진할 수 있다.

First-touch는 순서를 말하지만
상승분을 얼마나 반납했는지는 말하지 못한다.

“관심지표는 단기 경로 예측에는 추가 정보를 제공하지만, 최종 투자수익 보장을 의미하지는 않는다.

상승 장벽을 먼저 터치해도 이후 반납이 크면 T+20에는 부진할 수 있다

연구 질문을 “무엇을 살까?”에서
“어떤 경로를 위험이라 설명할까?”로 되돌렸다.

상승 장벽 선택 후
최종 반납 가능

“관심지표는 단기 경로 예측에는 추가 정보를 제공하지만, 최종 투자수익 보장을 의미하지는 않는다.

장벽 기반 Target 실험은 “무엇을 맞힐 것인가”를 다시 정리하게 해주었다

1

복잡한 3개 유형보다 “위험 여부”로 단순화
지속상승·관망·반전형 구분 → 부진 위험을 먼저 구분하자

2

“매수 추천”보다 “위험 경고”가 프로젝트 목적에 적합
초보 투자자의 의사결정을 위해 필요한 것은 추격 진입 전에 한 번 더 확인해야 할 위험 신호

3


최종수익률보다 실제 경로를 Target에 반영해야 함
단순 T+20 수익률이나 First-touch만으로는 상승→고점→반납 흐름을 충분히 설명하기 어렵다.

→ 다음 단계: 상승·하락 장벽을 이용해 “단기 반응”은 검증하되, T+20 부진위험과는 별도로 해석한다.

03-B

분석방향 설정

3분류의 한계에서 **Peak Give-back**의 도입



Peak Give-back 라벨 생성 변수

① MDD20

T~T+20 구간의 최대낙폭

② peak-return


T~T+40 시장조정수익률의 최고점

③ giveback_ratio

(최고점 - T+40 최종값) / 최고점

※ 5개 후보 비교 결과 40일 채택 (macro F1 최우수)

Peak Give-back 경로 예시



“한 번 충분히 상승했지만 이후 상승분을 크게 반납한 사건 “을 찾아내자

초기 라벨 순서

1 MDD20 $\leq$ -25%

→ 즉시 단기과열

2 Peak $\geq$ 10% & Give-back $\geq$ 50%

→ 단기과열

왜 먼저 MDD를 봤나?

- ✓ Peak 계산 전에 이미 20일 내 25% 이상 폭락한 사건 보호
- ✓ 상승폭이 작아 Give-back 비율이 불안정한 사례 보완
- ✓ 낙폭 위험을 보수적으로 우선 분류

초기에는 “놓치면 안 되는 위험”을 먼저 잡는 합리적인 보수 장치였다.

1,225건

유효 라벨 표본

470 vs 755

과열 vs 나머지

0.675확신도 ≥ 0.4 Precision**0.587**확신도 ≥ 0.4 Recall**10-seed 안정성****Precision 0.704 ± 0.018**
Recall 0.594 ± 0.021 **KNN 보조검증****상위 20% 실제 과열 0.743**
하위 20% 실제 과열 0.225

Feature Importance 상위 8개

순위	변수	Importance
1	시장_60일변동성	0.226
2	vol_sustain_10d	0.152
3	60일_변동성	0.108
4	vol_sustain_20d	0.093
5	vol_sustain_5d	0.073
6	5일_변동성	0.056
7	vol_sustain_30d	0.045
8	vol_trend_7_13	0.036

T 시점 예측에 T 이후 거래량을 사용

vol_sustain_5d, vol_sustain_10d,
vol_sustain_20d, vol_sustain_30d, vol_trend_7_13

-> 사건일 T 이후의 거래량 데이터를 사용해서 계산된 값

리크 제거 후 성능

0.704 → 0.473 0.594 → 0.242

Precision

Recall

커버리지 31.7% → 9.6%

이후 리크 제거한 변수로 여러 모델을 시도 해보았지만
사건일 정보만으로는 미래 반납을 충분히 구분할 수 없었다.

기존 질문

관심지표를 활용하면
급등당일에 지속과 과열을
예측할 수 있을까?

사건일 당일 정보만으로는
미래 경로를 충분히 구분하기 어려웠다

질문의 전환



새로운 질문


급등 당일에는 알기 어렵더라도,
초기 며칠의 실제 움직임을 관찰하면

이후 큰 부진 위험을 조기에 진단할 수 있지않을까?

03-C

분석방향 설정


판단 시점의 이동과 구조적 문제 해결



판단시점과 정보시점을 일치시키는 방식으로 수정


기존 방식

T에서 판단하면서 T+5까지의 정보를 입력에 사용



개선 방식

T+5까지 관찰한 뒤, 그 시점에서 처음 판단



미래 변수를 억지로 숨긴 것이 아니라, 해당 정보를 실제로 확인할 수 있는 T+5로 판단시점을 이동시켰다.

1 Target-Feature 순환

같은 경로 개념을 서로 다른 구간에서 반복 측정

기존 target

미래 Peak · Give-back · MDD

T + 5 feature

early_peak · early_giveback

Peak·Give-back
개념 공유

미래 예측인지, 이미 나타난
유사 패턴의 재측정인지
구분하기 어려움

2

Time-to-peak bias

같은 T+20 종료점이라도
Peak 시점에 따라 반납 가능 기간이 달라짐

A · 이른 Peak

Peak T+3

반납 가능 기간 17일

B · 늦은 Peak

Peak T+18

2일

T+20

3

MDD 경로 편향

단기과열의 약 48%가 MDD 우선조건; 낮은 Peak도 과열로 오분류

* MDD는 위험을 놓치지 않는 장점이 있었지만, “과열 후 반납”보다 일반 변동성을 우선 분류하는 부작용이 더 커졌다.




최종 Outcome = Direct T+20 BHAR | Train-fold 하위 35%를 위험 1로 정의

04

최종 결과물: 조기진단 모델

급등 후 첫 5거래일의 가격·거래량 경로로 위험을 조기 판정



13 사건일 스냅샷

STATIC · T 시점에 확정

수익률

ret 1 · 5 · 10 · 20d

변동성

volatility 5 · 20 · 60d

거래활동

volume ratio · trading value ratio · turnover

일중·추세

high-low range · up-day share · max return

+6 초기반응

Dynamic · Cutoff까지 누적관찰

early_return

상승유지

early_true_mdd

초기낙폭

early_peak_return

추가상승

volume_sustain

거래량 유지


early_giveback_ratio

초기 반납

volume_change_vs_T

사건일 대비 변화

Snapshot(cutoff) = 13개 사건일 정보 + cutoff까지 관찰된 초기변수 6개



AUC 0.78 의 의미

위험사건 · 비위험사건을 하나씩 비교했을 때, 위험사건에 더 높은 점수를 줄 확률 약 78%

정확도(Accuracy)가 아니라 순위 구분력(Ranking) 지표

$N = 20$, $q = 35$ 를 사용하는 근거

N과 q는 계산비용 문제로 동시(joint) 탐색 대신 순차적으로 결정 - N을 확정하고 그 N을 고정한 뒤 q를 찾음

N	q 6개 평균 AUC	표준편차	q에 따른 변동폭
30	0.5442 (평균 1위)	0.0340	0.087 (0.497~0.584)
20	0.5405 (평균 2위)	0.0122	0.030 (0.530~0.560)
15	0.5263	0.0341	-

Step 1. 관측기간 N 설정

N = 20 채택 · 안정성 기준

평균 AUC
0.5405

표준편차
0.0122

q 변동폭
0.030

- 평균만 보면 N=30이 근소하게 앞섰지만 평균 AUC가 근소하게 높다"는 이유만으로 N을 고르지 않았다.
- 컷오프 선택에 관계없이 안정적인(평균/표준편차 비율이 높은) N이 더 신뢰할 만한 target 정의라고 판단해 N=20을 최종 채택했다

Timing	20%	25%	30%	35%	40%	45%
T+3	0.626	0.593	0.602	0.642	0.633	0.628
T+5	0.726	0.729	0.735	0.748	0.746	0.732
T+7	0.753	0.755	0.763	0.777	0.774	0.775
T+10	0.838	0.842	0.852	0.860	0.849	0.840

q35 평균순위 1.00 | T+3·T+5·T+7·T+10 전 구간 1위

T+5 q35 vs q40: +0.0021, paired p=0.151 → 우월성 단정이 아니라 전 구간 일관성을 채택 근거로 사용

**급등 이후 부진위험을 구분하는 데
가장 중요한 정보는 무엇이었을까?**

초기반응 변수의 추가효과


사건일 가격·거래량 정보만 **0.622**

사건일 정보 + T~T+5 초기반응 **0.781**

초기 가격·거래량 반응 6개로 +0.159 AUC

보조변수 추가 결과 · AUC

- T + 5 RandomForest에서 기존 feature ablation




시장의 '관심'보다 중요한 것은 관심 이후 나타난 가격, 거래량의 실제 반응이었다

T+5 Feature Ablation: 가격·거래량(P)이 가장 안정적이었다

동일한 Direct T+20 위험 Target에서 변수군만 바꿔 비교 — P는 가격·거래량 + T~T+5 초기반응

Target: Train-fold Direct T+20 BHAR 하위 35% · Model: RandomForest · 검증: Purged Expanding Walk-Forward

T+5 변수군별 DEV WF AUC - 높을수록 T+20 부진위험 구분력이 큼



Step 2. 변수군 선택

P 채택 가격·거래량 + T~T+5 초기반응

DEV WF AUC

0.781

2025 AUC

0.787

2026 AUC


0.778

해석

시장지표는 거의 동일했지만, 관심·공매도 변수 추가는 T+5 기준에서 안정적인 개선으로 이어지지 않았다.

결론: Direct T+20 위험모델에서는 관심지표보다 T~T+5의 실제 가격·거래량 반응이 더 안정적인 설명력을 보였다.

→ 그래서 최종 feature는 P 중심으로 고정하고, 다음 단계에서 N=20·q cut-off 안정성을 선택했다.



기본 운영정책

F1_MAX

각 Timing의 DEV OOF에서 F1이 최대가 되는 기준

T + 5 **0.496175**T + 7 **DEV OOF 재산출**T + 10 **DEV OOF 재산출**

보조 정책

RECALL_80Recall ≥80% 만족하는 기준 중
Precision이 가장 높은 값**Threshold는 Risk Score를 실제 경고로 바꾸는 운영 기준이다.**

Split	AUC	Precision	Recall	F1	Balanced Acc.
2025	0.787	54.5%	70.9%	0.617	0.731
2026 Stress	0.778	52.1%	76.0%	0.619	0.695

2025 실제 분류 건수

TP 78

FP 65

FN 32

TN 198

2026 Stress 실제 분류 건수

TP 73

FP 67

FN 23

TN 114

실제 위험의 71–76%를 탐지했지만, 위험 경고의 약 절반은 오경보라는 한계가 남았다.

2025년

Timing	Precision	Recall	F1	Balanced Acc.
T	33.2%	84.5%	0.477	0.567
T+3	42.9%	76.4%	0.549	0.669
T+5	54.5%	70.9%	0.617	0.731
T+7	56.0%	68.2%	0.615	0.729
T+10	56.8%	75.5%	0.648	0.758

2026년 Stress

Timing	Precision	Recall	F1	Balanced Acc.
T	37.2%	95.8%	0.536	0.551
T+3	47.2%	88.5%	0.616	0.680
T+5	52.1%	76.0%	0.619	0.695
T+7	56.8%	82.3%	0.672	0.746
T+10	56.3%	79.2%	0.658	0.733

T의 높은 Recall은 무엇을 의미하나?

대부분을 '위험'으로 판정해 놓친 사건은 적었지만, Balanced Accuracy가 0.55 수준이라 실제 구분력은 낮았다.



T+5는 사건일 대비 Precision과 Balanced Accuracy가 개선되면서, 탐지율과 오경보 사이의 현실적인 균형을 보였다

처음의 가정

사건일 T의 정보만으로 이후 부진위험을 판단할 수 있을 것이다

분석으로 확인한 결과

당일 구분력은 낮았고, 초기 가격·거래량 경로가 쌓일수록 판단력이 개선됐다.



서비스 목적 급등을 예측하는것이 아니라, 급등 이후 상승이 버티는지를 관찰해 향후 부진위험을 조기에 진단한다

급등 탐지 → 초기 행동 관찰 → 위험 조기진단 → 판단 갱신

급등은 매수 신호가 아니라 관찰의 시작일 수 있다.

확인된 성과

Recall 71-76% 실제 위험 4건중 약 3건 탐지

운영시 고려할 균형

Precision 52-55% 자동판단보다 우선 점검용
경고에 적합

검토영역	현재 해석	다음 실험
경고정책	위험 탐지는 유지했지만 경고의 약 절반은 오경보	확신도·Risk Band별 선택적 출력
관심데이터	검색·뉴스의 양은 방향성을 구분하지 못함	금융 특화 감성점수와 발생순서 결합
표본범위	KOSPI200 Historical 260종목에 최적화	KOSDAQ·비KOSPI200 외부검증

이번 분석

검색량 · 기사 수

얼마나 많이 언급됐는가

남은 한계

긍정·부정 반응이 한데 섞임

같은 관심량도 의미가 다를 수 있음

후속 가설

금융 텍스트 감정분석

관심량 × 방향 × 발생순서 결합

문헌에서는 감정정보가 단순 관심량보다 수익률 예측에 더 유용할 수 있다는 결과가 보고됐다.


향후 검증: 금융 특화 감정점수 × 관심량 × 발생순서 → 동일 Walk-forward OOT에서 증분 성능 비교

※ 이번 프로젝트에서 직접 검증한 결론이 아니라, 후속 실험으로 제안하는 가설


05

결과 활용

시점별 위험판정과 근거를 대시보드에서 추적



조기진단 결과를 ‘시점의 변화’로 읽는 대시보드



<https://fin-da-project.vercel.app/>

01

사건을 찾고

종목·코드 검색과 진단 단계·위험 상태 필터로 대상을 좁힌다.

02

판단을 갱신하고

T+5 MAIN에서 시작해 T+7 재진단, T+10 최종판정으로 이동한다.

03

변화의 이유를 확인

위험 유지·해제·전환과 점수 변화를 가격·거래량 경로와 함께 본다.

대시보드 핵심

판단이 어떻게 바뀌는지를 보여준다

위험점수뿐 아니라 가격 경로와 판정 변화까지 함께 설명한다


402340_20260623 · EVENT 06/23 · AS-OF 2026.08.27

SK스퀘어

T+20 실제 결과 확인

Outcome 확인 가능

402340 · 현재 T+20



발표 들어주셔서 감사합니다

Q&A